

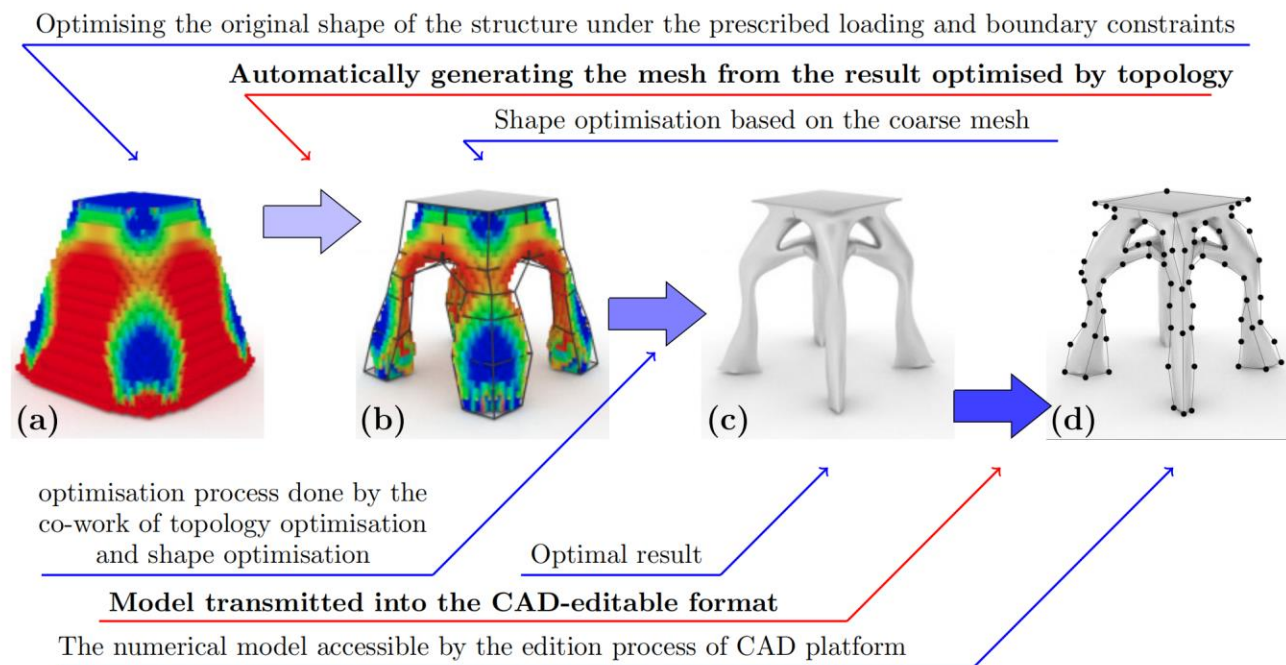
# 数值优化

- 背景
- 梯度优化理论
- 案例分析

# 数值优化 - 背景

- Everything can be optimised

- 几何形态能被优化
  - 曲线曲面拟合
  - 曲线曲面光顺
- 几何数据能被优化
  - 距离求值
  - 投影
  - 求交
- 设计方案能被优化
  - 拓扑优化
  - generative design (创成式设计)



# 数值优化 - 背景

- 优化分类

- 按方法:

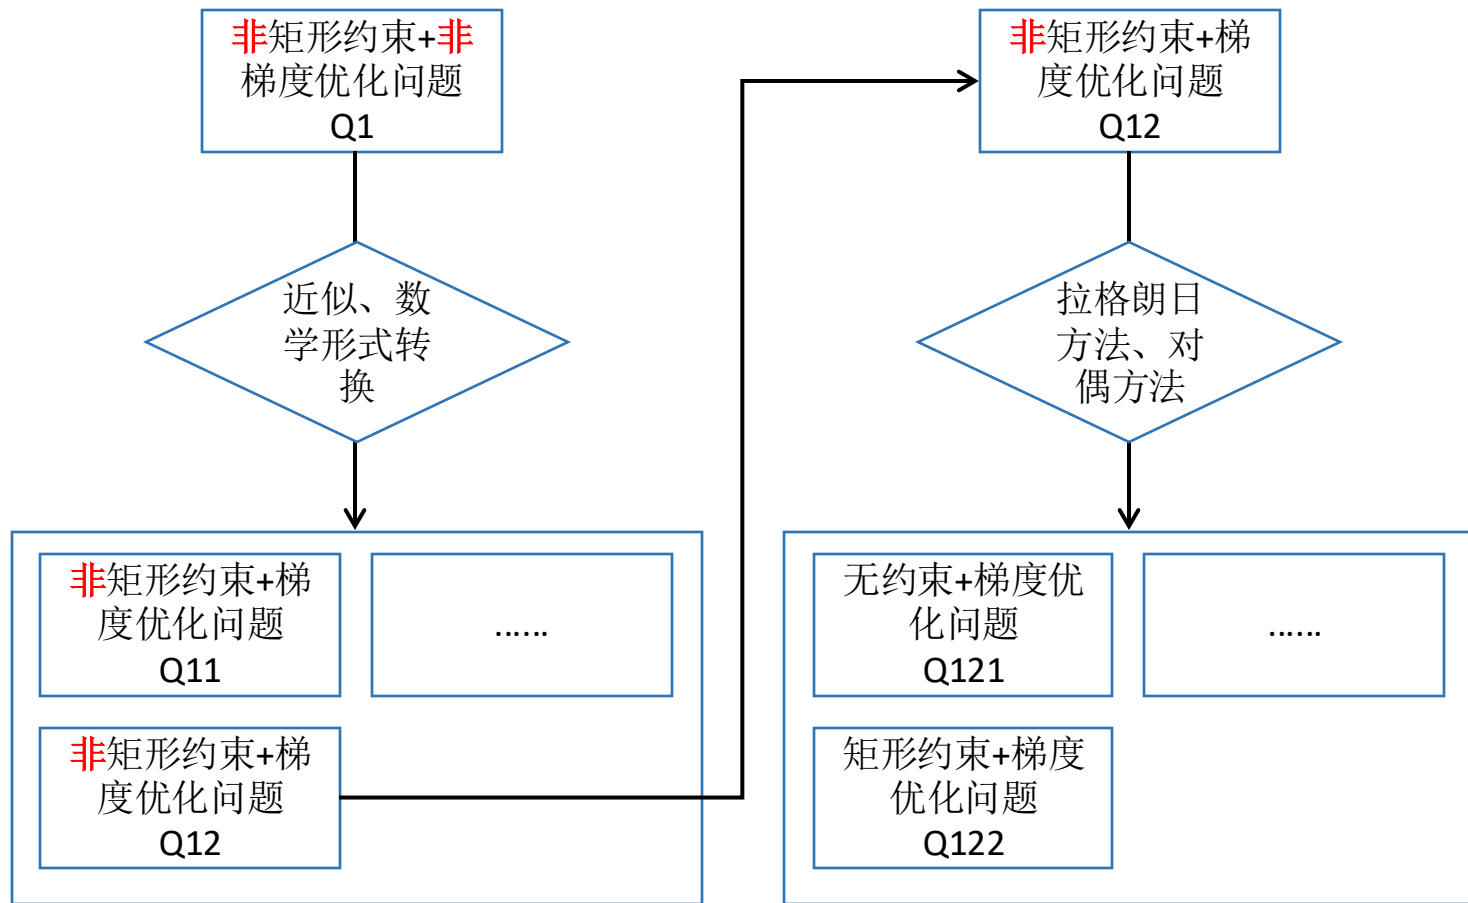
- 梯度优化, 极其常用, 但是在全局求解上有局限性
    - 非梯度优化 (花招很多, 收敛性有问题), 感兴趣可以看“贝叶斯优化”

- 按约束:

- 无约束及矩形区域约束 (数值上稳定), “简单约束”
    - 非矩形约束 (方法复杂)

- 最终

- 都会回到求解简单约束下的梯度问题
  - 那全局性怎么保证? 工程方法: 初值采样, 择优录取



# 数值优化 - 梯度优化理论

- 范式

- $\mathbf{x}$  = optimisation variable, 优化变量
- $f(\cdot)$  = objective function, 目标函数, 限定为  $\mathbb{R}^{n \times 1}$  到  $\mathbb{R}^1$  的映射
- $n$  = optimisation problem dimension, 优化问题维度
- $c$  = equality constraints, 等式约束, 均可以转化为不等式约束
- $g$  = inequality constraints, 不等式约束

- 优化结果

- $\mathbf{x}^* = \operatorname{argmin} f(\mathbf{x})$  or  $\operatorname{argmax} f(\mathbf{x})$
- $f^* = f(\mathbf{x}^*)$

$$\begin{aligned} & \min_{\mathbf{x}} f(\mathbf{x}) \text{ or } \max_{\mathbf{x}} f(\mathbf{x}) \\ s.t. \quad & \mathbf{x} \in \mathbb{R}^n, \\ & f \in \mathbb{R}, \\ & c_i(\mathbf{x}) = 0, \quad i \in [1, \dots, n_c], \\ & g_j(\mathbf{x}) < 0, \quad j \in [1, \dots, n_g]. \end{aligned}$$

# 数值优化 - 梯度优化理论

- 重要问题

- (1) “我们要优化什么？” 数学建模，将问题进行公式化，转化成为梯度优化标准范式，定义**优化变量与目标函数与约束**
- (2) “我们沿什么方向寻找结果？” 优化变量的**更新规则**，确定规则是可以保证问题收敛，并合理进行**初始值采样** (initial guess)
- (3) “我们要找到什么时候？” 梯度优化全部依赖于迭代方法，根据精度要求定义好**收敛条件**

- 说明

- (1) 是问题特化，对症下药
- (2) 有规律可循
- (3) 有常规设定

# 数值优化 - 梯度优化理论

- “我们要优化什么？”
  - 拉格朗日算子：将约束优化问题转化为无约束问题
  - 构造拉格朗日函数

$$L(\mathbf{x}, \lambda) = f(\mathbf{x}) + \lambda g(\mathbf{x})$$

- 原问题可以通过解下列方程组

$$\begin{cases} \nabla_{\mathbf{x}} L(\mathbf{x}, \lambda) = 0 \\ g(\mathbf{x}) = 0 \end{cases}$$

- $\nabla_{\mathbf{x}} L = 0$  意味着 $L$ 对于所有 $\mathbf{x}$ 的分量都是偏导为0，在目标函数 $f(\cdot)$ 为凸函数的时候就是最优解。上述方程组还可以理解为最优解要么在 $g$ 内的无约束问题的解，要不然就一定在边界上。可以阅读，解释得很通俗：  
<https://zhuanlan.zhihu.com/p/440297403>
- 那么问题来了？万一函数不是凸函数？

$$\begin{aligned} & \min_{\mathbf{x}} f(\mathbf{x}) \text{ or } \max_{\mathbf{x}} f(\mathbf{x}) \\ \text{s.t. } & \mathbf{x} \in \mathbb{R}^n, \\ & f \in \mathbb{R}, \\ & c_i(\mathbf{x}) = 0, \quad i \in [1, \dots, n_c], \\ & g_j(\mathbf{x}) < 0, \quad j \in [1, \dots, n_g]. \end{aligned}$$

# 数值优化 - 梯度优化理论

- 插一个队 “我们要找到什么时候？”
  - 首先明确，梯度优化方法都是迭代方法，指导迭代的最重要信息，就是我们怎么定义收敛条件
  - 抛砖引玉：假设迭代步 $k$ 和 $k+1$ 间出现了以下情况，则可以理解为收敛

$$\left| \frac{f(\mathbf{x}_{k+1}) - f(\mathbf{x}_k)}{f(\mathbf{x}_k)} \right| \leq \epsilon$$

- 这个微量 $\epsilon$ ，“epsilon”，是一个微量，也是迭代精度
- 更严格收敛条件，可以要求连续多次迭代步下降且相对误差满足一个微量，这里不做赘述，但要明确两点
  - 收敛条件均是迭代步之间相差小于某种精度
  - 严格的收敛条件必然会在迭代精度提升的同时导致迭代时间变长，“鱼和熊掌”

# 数值优化 - 梯度优化理论

- 再回到“我们沿什么方向寻找结果？”
  - 我们从收敛条件倒推迭代原则，假设我们有两个相邻的迭代步 $k$ 与 $k+1$ ，以及它们的函数值 $f_k$ 与 $f_{k+1}$ ，我们对 $f_{k+1}$ 进行泰勒展开

$$\begin{aligned} f(\mathbf{x}_{k+1}) &= f(\mathbf{x}_k) + \nabla f^\top(\mathbf{x}_k) \cdot (\mathbf{x}_{k+1} - \mathbf{x}_k) \\ &\quad + \frac{1}{2}(\mathbf{x}_{k+1} - \mathbf{x}_k)^\top \cdot \nabla^2 f(\mathbf{x}_k) \cdot (\mathbf{x}_{k+1} - \mathbf{x}_k) \end{aligned}$$

- 然后定义 $D = f_{k+1} - f_k$ ，所以 $D$ 应该收敛到0，即最小的非负数

$$D = \nabla f^\top(\mathbf{x}_k) \cdot (\mathbf{x}_{k+1} - \mathbf{x}_k) + \frac{1}{2}(\mathbf{x}_{k+1} - \mathbf{x}_k)^\top \cdot \nabla^2 f(\mathbf{x}_k) \cdot (\mathbf{x}_{k+1} - \mathbf{x}_k)$$



# 数值优化 - 梯度优化理论

- 在 $D$ 的定义下，只要能够满足 $D$ 一直下降到0就行，所以我们来设计一个迭代方法
- $-\nabla f(\mathbf{x}_k)$ 是 $f$ 在 $\mathbf{x}_k$ 处下降最快的方向
- 这里 $\alpha_k$ 是一个常数，所以迭代是沿着导数反方向进行的，那么这个 $\alpha_k$ 应该怎么设计才能使 $D$ 下降呢？带入 $\alpha_k$ ：

$$\mathbf{x}_{k+1} = \mathbf{x}_k - \alpha_k \nabla f(\mathbf{x}_k),$$

$$\mathbf{x}_{k+1} - \mathbf{x}_k = -\alpha_k \nabla f(\mathbf{x}_k).$$

$$D = -\alpha_k \|\nabla f(\mathbf{x}_k)\|^2 + \frac{1}{2} \alpha_k^2 \nabla f^\top(\mathbf{x}_k) \nabla^2 f(\mathbf{x}_k) \nabla f(\mathbf{x}_k)$$

- 然后 $D$ 对 $\alpha_k$ 求导为0:  $\alpha_k^* = \frac{\|\nabla f(\mathbf{x}_k)\|^2}{\nabla f^\top(\mathbf{x}_k) \nabla^2 f(\mathbf{x}_k) \nabla f(\mathbf{x}_k)}$
- 经典牛顿法的迭代规则为:  $\mathbf{x}_{k+1} = \mathbf{x}_k - \nabla^2 f(\mathbf{x}_k)^{-1} \nabla f(\mathbf{x}_k)$
- 下降方向为:  $\mathbf{d}_k = -\nabla^2 f(\mathbf{x}_k)^{-1} \nabla f(\mathbf{x}_k)$
- 步长为:  $\alpha_k = 1$

# 数值优化 - 梯度优化理论

- 所以要定义一个迭代方法只需要关注两点
  - 迭代方向  $\mathbf{d}_k$
  - 迭代步长  $\alpha_k$

$$\mathbf{x}_{k+1} = \mathbf{x}_k + \alpha_k \mathbf{d}_k$$

- 迭代方向的选择
  - 梯度下降法：直接用目标函数梯度作为  $\mathbf{d}_k$
  - Quasi-Newton法：采用一阶导数/二阶导数
  - BFGS法：采用一阶导数/二阶导数近似
- 迭代步长选择
  - Line search：线性搜索

# 数值优化 - 案例分析

- 案例背景
  - 场景：光学软件厂商，光线与光学透镜求交算法
  - 需求：效率达每秒十万级别光线求交完成，精度达10E-9


- 透镜方程均具有解析隐式表达

$$S(x, y, z) = 0$$

- 比如柱面

$$z = \frac{cR^2}{1 + \sqrt{1 - c^2R^2}}$$

$$S(x, y, z) = z - \frac{c(x^2 + y^2)}{1 + \sqrt{1 - c^2(x^2 + y^2)}} = 0$$



# 数值优化 - 案例分析

- 解题思路:

- 效率与要求都要，就要充分利用透镜面解析表达的特性
- 光线可以用解析表达，所以考虑直接利用解析形式进行求解








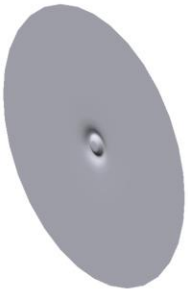
- 射线方程  $\mathbf{p}(t) = \mathbf{p}_0 + t \cdot \mathbf{p}_1$

- 交点必同时存在于 $S$ 和 $\mathbf{p}$ 上，所以把射线方程代入曲面方程

$$S(t) = S(x(t), y(t), z(t)) = 0$$

- 上述方程求解可以转换为优化问题，完成数学建模

$$\min_t F(t), \quad F(t) = \frac{1}{2}(S(x(t), y(t), z(t)))^2$$

Cylindrical	Biconic	Zernike	XY polynomial
			
Ytoroid	Asphere	Oddpolynomial	Superconic
			

# 数值优化 - 案例分析

- 更新策略：会用到 $F(t)$ 的一阶导数和二阶导数，链式法则推导

$$\frac{\partial S}{\partial t} = \frac{\partial S}{\partial x} \frac{\partial x}{\partial t} + \frac{\partial S}{\partial y} \frac{\partial y}{\partial t} + \frac{\partial S}{\partial z} \frac{\partial z}{\partial t}$$

$$\frac{\partial F}{\partial t} = S \cdot \frac{\partial S}{\partial t}$$

$$\frac{\partial^2 S}{\partial t^2} = \frac{\partial^2 S}{\partial x^2} \frac{\partial x}{\partial t} \frac{\partial x}{\partial t} + \frac{\partial^2 S}{\partial y^2} \frac{\partial y}{\partial t} \frac{\partial y}{\partial t} + \frac{\partial^2 S}{\partial z^2} \frac{\partial z}{\partial t} \frac{\partial z}{\partial t} + 2\left(\frac{\partial^2 S}{\partial xy} \frac{\partial x}{\partial t} \frac{\partial y}{\partial t} + \frac{\partial^2 S}{\partial xz} \frac{\partial x}{\partial t} \frac{\partial z}{\partial t} + \frac{\partial^2 S}{\partial yz} \frac{\partial y}{\partial t} \frac{\partial z}{\partial t}\right)$$

$$\frac{\partial^2 F}{\partial t^2} = \left(\frac{\partial S}{\partial t}\right)^2 + S \cdot \frac{\partial^2 S}{\partial t^2}$$

- 收敛条件：常规即可
- 初始值：离散网格快速粗筛，GPU加速